

UNIVERSIDADE DO ESTADO DA BAHIA

Departamento de Ciências Exatas e da Terra

Aprendizagem de Máquina Clássica

Trabalho Prático 2

Predição de Biodegradabilidade Molecular com Técnicas de Aprendizado de Máquina Clássica

Dataset: QSAR Biodegradation

Alunos:

Caio Seixas de Melo

Gabriel Cerqueira Santos Rodrigues

Luiz Vinícius Pereira de Oliveira Souza

Luiza de Sá Florentino Limoeiro

Salvador, 2026

Sumário

1	Apresentação do Dataset	2
2	Análise e Preparação dos Dados	4
2.1	Análise Exploratória dos Dados (EDA)	4
2.2	Limpeza e Codificação	6
2.3	Divisão Treino/Teste	7
2.4	Seleção de Features	7
2.5	Remoção de Outliers	8
2.6	Normalização	8
2.7	Balanceamento (SMOTE)	9
3	Definição do Protocolo Experimental	9
4	Modelagem Supervisionada	9
4.1	Árvore de Decisão	9
4.2	K-Nearest Neighbors	10
4.3	Rede Neural Artificial (MLP)	10
4.4	Hiperparâmetros Seleccionados	10
5	Modelagem Não Supervisionada	10
5.1	Preparação dos Dados para o K-Means	10
5.2	Escolha do Número de Clusters	11
5.3	Resultados do K-Means	11
6	Resultados	13
6.1	Modelos Supervisionados	13
6.2	Modelagem Não Supervisionada	14
7	Análise Crítica Comparativa	15
7.1	Por que certos modelos se saíram melhor ou pior	15
7.2	Como o pré-processamento influenciou os resultados	15
7.3	Limitações do dataset	16
7.4	Em que medida os clusters fazem sentido	16
7.5	Se a estrutura não supervisionada ajuda a entender o problema	16
8	Conclusão	17

1 Apresentação do Dataset

O dataset de biodegradação QSAR foi construído pelo Grupo de Pesquisa em Quimiometria e QSAR de Milão (Mansouri et al., 2013). O conjunto de dados contém valores para 41 atributos (descritores moleculares) utilizados para classificar substâncias químicas em duas classes: *prontamente biodegradável* (RB) e *não prontamente biodegradável* (NRB). Após remoção de duplicatas e registros com valores ausentes, o dataset final conta com **1.052 amostras válidas**.

Em relação à distribuição das classes, o dataset apresenta desbalanceamento moderado: 699 amostras pertencem à classe NRB (66,4%) e 353 amostras à classe RB (33,6%), conforme ilustrado na Figura 1. Essa proporção aproximada de 2:1 é relevante para as decisões de pré-processamento, especialmente a escolha do SMOTE para balanceamento durante o treinamento.




Figura 1: Distribuição das classes RB e NRB no dataset QSAR Biodegradation.

Os 41 descritores moleculares cobrem propriedades topológicas, eletrônicas e estruturais das moléculas, conforme listado na Tabela 1.

Tabela 1: Descritores moleculares do dataset QSAR Biodegradation.

#	Nome	Descrição
1	SpMax_L	Autovalor principal da matriz de Laplace
2	J_Dz(e)	Índice tipo Balaban (matriz de Barysz / eletronegatividade)
3	nHM	Número de átomos pesados
4	F01[N-N]	Frequência de N-N na distância topológica 1
5	F04[C-N]	Frequência de C-N na distância topológica 4
6	NssssC	Número de átomos do tipo ssssC

continua na próxima página

Tabela 1 – continuação

#	Nome	Descrição
7	nCb-	Número de C(sp ²) substituídos no benzeno
8	C%	Porcentagem de átomos de C
9	nCp	Número de C(sp ³) primários terminais
10	nO	Número de átomos de oxigênio
11	F03[C-N]	Frequência de C-N na distância topológica 3
12	SdssC	Soma dos estados E de dssC
13	HyWi_B(m)	Índice hiper-Wiener (logarítmico) da matriz de Burden (massa)
14	LOC	Índice cêntrico de Lopping
15	SM6_L	Momento espectral de ordem 6 da matriz de Laplace
16	F03[C-O]	Frequência de C-O na distância topológica 3
17	Me	Eletronegatividade média de Sanderson (escalada)
18	Mi	Primeiro potencial de ionização médio (escalado)
19	nN-N	Número de N hidrazinas
20	nArNO2	Número de grupos nitro aromáticos
21	nCRX3	Número de CRX3
22	SpPosA_B(p)	Soma espectral positiva normalizada (Burden / polarizabilidade)
23	nCIR	Número de circuitos
24	B01[C-Br]	Presença/ausência de C-Br na distância topológica 1
25	B03[C-Cl]	Presença/ausência de C-Cl na distância topológica 3
26	N-073	Ar2NH / Ar3N / Ar2N-Al / R..N..R
27	SpMax_A	Autovalor principal da matriz de adjacência (Lovasz-Pelikan)
28	Psi_i_1d	Índice de pseudoconectividade do estado intrínseco (tipo 1d)
29	B04[C-Br]	Presença/ausência de C-Br na distância topológica 4
30	SdO	Soma dos estados E de dO
31	TI2_L	Segundo índice de Mohar da matriz de Laplace

continua na próxima página

Tabela 1 – continuação

#	Nome	Descrição
32	nCrt	Número de C(sp3) terciários do anel
33	C-026	R--CX--R
34	F02[C-N]	Frequência de C-N na distância topológica 2
35	nHDon	Número de doadores de ligações de hidrogênio (N e O)
36	SpMax_B(m)	Autovalor principal da matriz de Burden (massa)
37	Psi_i_A	Índice de pseudoconectividade do estado intrínseco (média S)
38	nN	Número de átomos de nitrogênio
39	SM6_B(m)	Momento espectral de ordem 6 da matriz de Burden (massa)
40	nArCOOR	Número de ésteres aromáticos
41	nX	Número de átomos de halogênio
42	Classe experimental	prontamente biodegradável (RB) e não prontamente biodegradável (NRB)

2 Análise e Preparação dos Dados

O pré-processamento seguiu uma sequência rígida para evitar vazamento de informações: (1) EDA sobre o dataset completo; (2) divisão treino/teste; (3) seleção de features; (4) remoção de outliers; (5) normalização Z-Score; (6) balanceamento SMOTE por fold. Cada etapa é descrita a seguir.

2.1 Análise Exploratória dos Dados (EDA)

Antes de qualquer transformação, foi conduzida uma Análise Exploratória dos Dados (EDA) sobre o conjunto original completo. A distribuição das 12 features de maior variância por classe é apresentada na Figura 2, e o mapa de correlação das 20 features de maior variância na Figura 3.




Figura 2: Distribuição das 12 features com maior variância, separadas por classe.




Figura 3: EDA — Mapa de correlação das 20 features com **maior variância** (conjunto completo, antes da seleção de features).

A EDA confirmou ausência de valores nulos ou duplicatas e identificou pares de features altamente correlacionados entre as variáveis de maior variância, como $F03[C-N] \times F04[C-N]$ com $r = 0,87$ e $F03[C-O] \times nO$ com $r = 0,84$. Importante notar que este mapa cobre as features de maior variância, não necessariamente as mais discriminativas — a análise do conjunto efetivamente selecionado para os modelos é apresentada na Seção 2.4.

2.2 Limpeza e Codificação

O dataset foi carregado e passou por limpeza: remoção de registros duplicados e de amostras com valores faltantes. A verificação confirmou ausência de nulos, tornando desnecessária qualquer imputação. A variável alvo (*experimental class*) foi convertida para valores numéricos via *Label Encoding* ($NRB = 0$, $RB = 1$).

2.3 Divisão Treino/Teste

Os dados foram divididos em treinamento (80%) e teste (20%) de forma estratificada, preservando a proporção original das classes em ambos os subconjuntos. O conjunto de teste foi completamente isolado desde esse momento, sem participar de nenhuma etapa subsequente de transformação ou ajuste.

2.4 Seleção de Features

Foi treinado um modelo *Random Forest* com `class_weight= "balanced"` exclusivamente sobre os dados de treinamento para identificar os 20 atributos mais relevantes. A importância calculada pelo modelo é apresentada na Figura 4. A redução de 41 para 20 features elimina atributos pouco informativos, reduz o custo computacional e melhora a generalização dos modelos.




Figura 4: Top 20 features por importância no *Random Forest*.

O mapa de correlação das features efetivamente selecionadas (Figura 5) revelou alta colinearidade na família de índices espectrais SpMax/SM6: as features SpMax_B(m), SpMax_L, SpMax_A, SM6_B(m) e SM6_L apresentam correlações superiores a $r = 0,91$ entre si. Vale notar que o conjunto de features selecionado por importância RF e o conjunto de maior variância se sobrepõem em apenas 50%, evidenciando que variância e relevância preditiva são conceitos distintos.




Figura 5: Mapa de correlação entre as 20 features seleccionadas por importância RF (conjunto de treino, após seleção). Note que este conjunto difere em 50% das features de maior variância.

2.5 Remoção de Outliers

O algoritmo *Isolation Forest* foi aplicado com parâmetro de contaminação de 5% exclusivamente sobre o conjunto de treinamento, removendo 42 amostras anômalas ($\approx 5\%$) e reduzindo o treino de 841 para 799 amostras. O conjunto de teste foi preservado integralmente.

2.6 Normalização

Os dados foram normalizados pelo método Z-Score (`StandardScaler`): média e desvio padrão calculados exclusivamente sobre o treino limpo, aplicados passivamente ao teste. A normalização é crítica para o KNN (distâncias) e para a MLP (gradientes).

2.7 Balanceamento (SMOTE)

O *SMOTE* foi integrado a um pipeline do `imbalanced-learn` e aplicado dinamicamente em cada dobra do 5-Fold Cross Validation, garantindo que amostras sintéticas nunca contaminem o fold de validação durante a busca de hiperparâmetros.

3 Definição do Protocolo Experimental

Os dados foram divididos estratificadamente em 80% para treinamento e 20% para teste. O conjunto de teste foi isolado desde o início e utilizado exclusivamente na avaliação final.

A validação dos hiperparâmetros foi conduzida via **5-Fold Cross Validation** dentro do conjunto de treinamento. Em cada dobra, o pipeline executou automaticamente: (1) aplicação do SMOTE apenas nos dados de treino da dobra e (2) treinamento do classificador com a configuração avaliada. Essa estratégia elimina o risco de vazamento entre treino e validação, pois as amostras sintéticas são geradas com dados exclusivos de cada iteração.

A busca de hiperparâmetros foi realizada por *Grid Search* exaustivo. O critério de seleção foi o **F1-Score Macro** médio das cinco dobras, escolhido por penalizar igualmente erros em ambas as classes independentemente do desbalanceamento.

Após identificar os melhores hiperparâmetros, o modelo otimizado foi treinado sobre todo o conjunto de treinamento e avaliado no conjunto de teste. Por nunca ter participado de nenhuma etapa de ajuste, os resultados no teste representam uma estimativa confiável da capacidade de generalização.

4 Modelagem Supervisionada

Foram utilizados três algoritmos com características distintas de aprendizado, permitindo comparações entre abordagens baseadas em regras, proximidade e aprendizado não linear.

4.1 Árvore de Decisão

A Árvore de Decisão foi escolhida por sua interpretabilidade e capacidade de capturar relações não lineares por meio de divisões hierárquicas dos dados. Os hiperparâmetros otimizados foram: `criterion` (Gini ou Entropia), `max_depth`, `min_samples_split`, `min_samples_leaf` e `class_weight`.

4.2 K-Nearest Neighbors

O KNN classifica amostras com base na classe majoritária entre os k vizinhos mais próximos no espaço de features. Foram otimizados: `n_neighbors`, `weights` (uniforme ou ponderado por distância) e `metric` (Euclidiana ou Manhattan).

4.3 Rede Neural Artificial (MLP)

O MLP foi escolhido por sua capacidade de modelar relações altamente não lineares. Os hiperparâmetros otimizados foram: `hidden_layer_sizes` (arquiteturas com 1 e 2 camadas ocultas), `activation` (ReLU, tanh, logistic), `alpha` (regularização L2) e `learning_rate_init`.

4.4 Hiperparâmetros Seleccionados

Após o GridSearchCV com 5-Fold CV, os melhores hiperparâmetros encontrados foram:

Tabela 2: Melhores hiperparâmetros seleccionados por GridSearchCV.

Modelo	Hiperparâmetros
Árvore de Decisão	<code>criterion=entropy</code> , <code>max_depth=15</code> , <code>min_samples_leaf=1</code> , <code>min_samples_split=10</code>
KNN	<code>metric=euclidean</code> , <code>n_neighbors=5</code> , <code>weights=distance</code>
MLP	<code>activation=relu</code> , <code>hidden_layer_sizes=(50,)</code> , <code>alpha=0.1</code> , <code>learning_rate_init=0.001</code>

Destaca-se que a MLP seleccionada é deliberadamente simples e regularizada (`alpha=0.1`): o 5-Fold CV identificou sobreajuste nas arquiteturas maiores testadas. O KNN com $k = 5$ e distância Euclidiana reflete a estrutura local dos dados após normalização Z-Score.

5 Modelagem Não Supervisionada

5.1 Preparação dos Dados para o K-Means

Para a trilha não supervisionada foi preparado um dataset exclusivo, partindo das 20 features seleccionadas pelo Random Forest no conjunto de treinamento (80%). O Isolation Forest (contaminação = 5%) foi aplicado de forma independente, resultando em 799 amostras limpas. Uma normalização Z-Score própria foi ajustada sobre esse subconjunto. Todo o processo ocorreu sem acesso aos rótulos, preservando o carácter não supervisionado.

5.2 Escolha do Número de Clusters

Para determinar k , foram utilizados dois critérios em conjunto com k variando de 2 a 10 (Figura 6).




Figura 6: Método do Cotovelo (inércia) e Silhouette Score para $k = 2$ a 10.

Método do Cotovelo: a curva de inércia decresce suavemente de $k = 2$ a $k = 10$, sem cotovelo nítido. As maiores quedas ocorrem nas transições $k = 2 \rightarrow 3$ e $k = 3 \rightarrow 4$.

Silhouette Score: os valores são baixos em toda a faixa (máximo $\approx 0,172$ em $k = 5$), refletindo sobreposição natural entre as classes moleculares. Nenhum k domina claramente os demais.

Decisão: adotou-se $k = 2$ como escolha principal por três razões: (i) o problema é originalmente binário (RB vs. NRB), e testar se o K-Means recupera essa estrutura sem supervisão é a pergunta central da análise; (ii) $k = 2$ corresponde à maior redução de inércia; (iii) os silhouette scores são próximos ao longo de toda a faixa, sem dominante claro. Como análise complementar, executou-se também $k = 5$ (melhor silhouette local).

5.3 Resultados do K-Means

Tabela 3: Métricas do K-Means para $k = 2$ (principal) e $k = 5$ (complementar).

k	Inércia	Silhouette
2 (principal)	13.114,2	0,1635
5 (complementar)	9.363,5	0,1724

Para $k = 2$, a tabela de contingência entre clusters e classes reais revelou:

Tabela 4: Tabela de contingência: clusters K-Means ($k = 2$) vs. classes reais.

	Cluster 0	Cluster 1
NRB	169	354
RB	193	83
Classe majoritária	RB (53,3%)	NRB (81,0%)

O Cluster 1 concentrou 81,0% das amostras NRB, indicando que moléculas não biodegradáveis compartilham padrões moleculares distintivos detectáveis sem supervisão. A visualização PCA dos clusters é apresentada na Figura 7, e a análise dos centroides nas Figuras 8 e 9.




Figura 7: Projeção PCA 2D dos clusters K-Means (esq.) e classes reais (dir.).




Figura 8: Perfil dos centroides dos clusters em escala Z-Score.




Figura 9: Features que mais diferenciam os clusters (diferença absoluta entre centroides).

6 Resultados

6.1 Modelos Supervisionados

Os modelos foram avaliados sobre o conjunto de teste (211 amostras: 140 NRB e 71 RB). A Tabela 5 consolida as métricas obtidas.

Tabela 5: Comparativo dos modelos supervisionados no conjunto de teste.

Modelo	Acurácia	F1-Macro	F1-NRB	F1-RB	Recall-M.	AUC-ROC
Árvore de Decisão	80,6%	0,782	0,854	0,709	0,781	0,801
KNN	83,0%	0,820	0,862	0,778	0,844	0,907
MLP	85,3%	0,838	0,889	0,789	0,844	0,901

As matrizes de confusão individuais são apresentadas na Figura 10, as curvas ROC na Figura 11 e o gráfico radar comparativo na Figura 12.




Figura 10: Matrizes de confusão: Árvore de Decisão (esq.), KNN (centro) e MLP (dir.).




Figura 11: Curvas ROC dos três modelos no conjunto de teste.




Figura 12: Gráfico radar comparativo das métricas por modelo.

6.2 Modelagem Não Supervisionada

O K-Means com $k = 2$ obteve Inércia de 13.114,2 e Silhouette Score de 0,1635. O Cluster 1 concentrou 354 amostras NRB e 83 RB (81,0% de pureza NRB), enquanto o Cluster 0 ficou com 169 NRB e 193 RB (53,3% RB). O baixo Silhouette confirma sobreposição entre as classes no espaço molecular — coerente com o teto de 85,3% atingido pelos modelos supervisionados. A análise complementar com $k = 5$ (Silhouette = 0,1724) apresentou melhora marginal sem ganho interpretativo proporcional. A

variância explicada pelos dois componentes PCA usados na visualização (Figura 7) foi de 46,6%, indicando que parte relevante da estrutura dos dados ainda reside nas dimensões omitidas.

7 Análise Crítica Comparativa

7.1 Por que certos modelos se saíram melhor ou pior

O ordenamento $\text{MLP} > \text{KNN} > \text{Árvore de Decisão}$ em F1-Macro ($0,838 > 0,820 > 0,782$) é consistente com as características estruturais de cada algoritmo frente ao problema.

A **Árvore de Decisão** constrói fronteiras de decisão retangulares e rígidas, inadequadas para descritores moleculares com relações contínuas e sobrepostas entre classes. O F1-RB de 0,709 — o mais baixo entre os três — evidencia maior dificuldade de capturar a classe minoritária, cujas regiões no espaço de features são fragmentadas e não separáveis por divisões ortogonais simples.

O **KNN** se beneficiou diretamente da normalização Z-Score: sem ela, features com variância absoluta elevada (como **Me**, variância = 236.517) dominariam o cálculo de distâncias. A distância Euclidiana com $k = 5$ vizinhos ponderados por distância revelou-se eficaz para capturar a estrutura local dos dados normalizados. O alto recall de RB (0,89) indica boa sensibilidade à classe minoritária, embora ao custo de maior taxa de falsos positivos (precisão-RB = 0,69). A AUC-ROC de 0,907 — a mais alta — demonstra excelente capacidade de ranqueamento.

A **MLP** atingiu o melhor F1-Macro ao modelar relações não lineares complexas entre descritores. A arquitetura selecionada pelo 5-Fold CV foi deliberadamente simples: 50 neurônios em camada única com regularização $\alpha = 0,1$. Arquiteturas maiores estavam sobreajustando à variância do treino — o 5-Fold CV identificou esse overfitting e selecionou um modelo mais parcimonioso. O perfil mais equilibrado entre NRB e RB (F1 de 0,889 e 0,789) sugere que a rede aprendeu representações menos enviesadas para a classe majoritária.

7.2 Como o pré-processamento influenciou os resultados

A normalização Z-Score foi crítica para KNN e MLP. A seleção de features por importância RF capturou poder discriminativo distinto da simples variância: 9 das 20 features selecionadas têm variância abaixo do Top 20 por variância, e os conjuntos se sobrepõem em apenas 50%. A feature **Mi**, com a menor variância do dataset (0,0009), foi selecionada por ser discriminativa, ilustrando que variância e relevância preditiva são conceitos distintos.

O mapa de correlação das features selecionadas revelou alta colinearidade na família SpMax/SM6 ($r > 0,91$). Essa redundância é tolerada por árvores de decisão (que dividem sobre uma feature por vez), mas pode inflar artificialmente a importância do grupo no cálculo de distâncias (KNN) e nos gradientes (MLP).

O SMOTE aplicado por fold no pipeline foi metodologicamente mais rigoroso do que uma aplicação global. Na abordagem global, amostras sintéticas poderiam ser geradas a partir de toda a base de treino e avaliadas como validação, inflando as métricas de seleção de hiperparâmetros. Com o pipeline, cada fold cria seus próprios sintéticos apenas com os dados disponíveis naquela iteração.

7.3 Limitações do dataset

O desbalanceamento de classes (66,4%/33,6%) é a principal limitação. Apesar do SMOTE, todos os modelos apresentaram F1-RB consistentemente inferior ao F1-NRB (gap de 10–15 pontos percentuais). O conjunto de teste preserva a distribuição original e contém apenas 71 amostras RB — cada erro pesa mais nessa classe. A interpolação do SMOTE também pode não capturar toda a diversidade estrutural das moléculas biodegradáveis reais.

A alta colinearidade na família SpMax/SM6 implica que o budget de 20 features contém redundâncias que poderiam ser substituídas por descritores mais independentes, potencialmente ampliando a diversidade de informação disponível para os modelos.

7.4 Em que medida os clusters fazem sentido

O K-Means com $k = 2$ recuperou parcialmente a estrutura binária sem supervisão: o Cluster 1 apresentou 81,0% de pureza NRB, resultado expressivo dado que o algoritmo não teve acesso aos rótulos. O Silhouette Score baixo (0,164) é consistente com o teto de performance supervisionada a 85,3%: a dificuldade de separação é intrínseca ao problema, não um artefato do K-Means.

7.5 Se a estrutura não supervisionada ajuda a entender o problema

Sim. A análise dos centroides revelou que os descritores que mais diferenciam os clusters são exatamente os de maior importância no Random Forest — índices espectrais topológicos como SpMax e SM6. Isso indica coerência entre o que o aprendizado não supervisionado descobre e o que os modelos supervisionados utilizam para classificar. A existência de um cluster NRB com 81% de pureza apoia a hipótese de que moléculas estruturalmente mais complexas são menos propensas à biodegradação, interpretação compatível com o conhecimento químico sobre o tema.

8 Conclusão

Este trabalho abordou a predição de biodegradabilidade molecular por meio de técnicas clássicas de aprendizado de máquina supervisionado e não supervisionado, aplicadas ao dataset QSAR Biodegradation.

Na trilha supervisionada, a Rede Neural MLP demonstrou o melhor desempenho geral, com acurácia de 85,3%, F1-Macro de 0,838 e AUC-ROC de 0,901. O KNN apresentou a maior AUC-ROC (0,907) e o melhor recall para a classe RB. A Árvore de Decisão, apesar da maior interpretabilidade, ficou aquém dos demais pela limitação estrutural de suas fronteiras de decisão frente à sobreposição das classes.

Na trilha não supervisionada, o K-Means com $k = 2$ recuperou parcialmente a estrutura binária do problema sem acesso aos rótulos, com o Cluster 1 apresentando 81,0% de pureza para NRB. O Silhouette Score baixo (0,164) confirmou a sobreposição natural entre as classes, corroborando o teto de performance observado nos modelos supervisionados.

As principais dificuldades foram o desbalanceamento de classes — que persiste mesmo após o SMOTE e impacta a detecção da classe RB — e a multicolinearidade entre descritores da família SpMax/SM6, que exige atenção na interpretação das importâncias. O protocolo com 5-Fold CV e SMOTE por fold mostrou-se mais rigoroso do que validações com split fixo.

Como aprendizados centrais, o trabalho reforçou: a importância da separação estrita entre conjuntos desde o início do pipeline; a distinção entre variância e relevância preditiva na seleção de features; e o valor da análise conjunta de métricas — acurácia isolada não captura o comportamento por classe em problemas desbalanceados.

Referências

Kamel Mansouri, Tine Ringsted, Davide Ballabio, Roberto Todeschini, and Viviana Consonni. QSAR biodegradation, 2013. URL <https://doi.org/10.24432/C5H60M>.